# PATTERN MATCHING

Ir. Rismayani, S.Kom., M.T

# Algoritma Pattern Matching

- Pattern matching adalah sebuah proses pencarian pola dalam sekumpulan token yang berurutan.
- Pada umumnya, pattern matching digunakan untuk mencari pola karakter alfabet dalam sebuah kalimat (string).
- Persoalan pattern matching dirumuskan sebagai berikut: Diberikan sebuah teks (text), yakni string yang memiliki panjang n karakter; dan sebuah pola (pattern), yakni string dengan panjang m karakter (m < n) yang akan dicari di dalam text.

#### Ilustrasi

• Text: With great power, comes great bills.

• Pattern: eat

 Pattern matching akan mencari kemunculan pertama (dari kiri) pattern pada text. Dalam kasus ini, ditemukan pattern 'eat' pada karakter ke-8 text (spasi termasuk sebuah karakter/token).


#### Pendekatan


- Brute force,
- Boyer-Moore
- Karp-Rabin
- Knuth-MorrisPratt (KMP) Algorithm


# 1. What is Pattern Matching?


- Definisi: Diberikan:
  - 1. T: teks (text), yaitu (long) string yang panjangnya n karakter
  - 2. P: pattern, yaitu string dengan panjang m karakter (asumsi  $m \ll n$ ) yang akan dicari di dalam teks.
  - Carilah (*find* atau *locate*) lokasi pertama di dalam teks yang bersesuaian dengan *pattern*.
- Contoh:
  - ◆ T: "the rain in spain stays mainly on the plain"
  - P: "main"

## Aplikasi:









# Konsep String

 $\diamond$  Assume S is a string of size m.

$$S = x_0 x_1 \dots x_{m-1}$$

- $\star$  A *prefix* of S is a substring S[0 .. k]
- A Suffix of S is a substring S[k ... m 1]
  - -k is any index between 0 and m-1

# Examples



- \* All possible prefixes of S:
  - "a", "an", "and", "andr", "andre", "andrew"

- \* All possible suffixes of S:
  - "w", "ew", "rew", "drew", "ndrew", "andrew"

## Algoritma Brute Force

- Pada pendekatan ini, setiap karakter pada pattern dicocokkan dengan karakter pada text secara straightforward (lempang).
- Jika diketahui text T[1..n] dan pattern P[1..m] adalah array of character dengan panjang masing-masing n dan m karakter, maka langkah penyelesaian dengan algoritma brute force adalah:
- 1. Sejajarkan pattern dan text pada awal karakter (P[i] dan T[j]) untuk dibandingkan, dimana i = j = 1.
- 2. Bergerak dari kiri ke kanan, bandingkan setiap karakter pada pattern dengan karakter pada text. Perbandingan dilakukan dengan membandingkan P[i] dan T[j], kemudian P[i+1] dan T[j+1], dst. sampai ditemukan:

- a. semua karakter pada pattern ditemukan (pencarian selesai), atau
- b. terdapat mismatch (ketidakcocokan) karakter
- 3. Jika terdapat mismatch dan text belum habis, ulangi langkah 2 dengan j = j+1 (menggeser pattern sebanyak 1 karakter)
- Berikut ilustrasi algoritma brute force:

```
• Text: Bear eats.
```


- Pattern: eat
- Bear eats.

- Pattern 'eat' ditemukan pada karakter ke-6 text dengan 10 perbandingan karakter.
- Jika menghitung jumlah operasi perbandingan yang dilakukan, kompleksitas waktu terbaik algoritma brute force adalah O(n).
- Pada kasus terburuk, dilakukan sebanyak m(nm+1) perbandingan karakter.

- Brute force : pendekatan yang lempang (straightforward) untuk memecahkan suatu masalah. Biasanya didasarkan pada:
  - pernyataan masalah (problem statement)
  - definisi konsep yang dilibatkan.
- Algoritma brute force memecahkan masalah dengan sangat sederhana, langsung, jelas (obvious way).
- Algoritma brute force merupakan algoritma pencocokan string yang ditulis tanpa memikirkan peningkatan performa. Algoritma ini sangat jarang dipakai dalam praktik, namun berguna dalam studi pembanding dan studi-studi lainnya.

#### CARA KERJA

- 1.Secara sistematis, langkah-langkah yang dilakukan algoritma brute force pada saat mencocokkan string adalah: Algoritma brute force mulai mencocokkan pattern pada awal teks.
- 2. Dari kiri ke kanan, algoritma ini akan mencocokkan karakter per karakter pattern dengan karakter di teks yang bersesuaian, sampai salah satu kondisi berikut dipenuhi:
  - 1. Karakter di pattern dan di teks yang dibandingkan tidak cocok (mismatch).
  - 2. Semua karakter di pattern cocok. Kemudian algoritma akan memberitahukan penemuan di posisi ini.
- 3. Algoritma kemudian terus menggeser pattern sebesar satu ke kanan, dan mengulangi langkah ke-2 sampai pattern berada di ujung teks.



```
Pattern: NOT
Teks: NOBODY NOTICED HIM
  NOBODY NOTICED HIM
1 NOT
   NOT
   NOT
     TOM
5
      NOT
       NOT
        NOT
         NOT
```

#### Brute Force in Java

Return index where pattern starts, or -1

```
public static int brute (String text, String pattern)
{ int n = text.length(); // n is length of text
  int m = pattern.length(); // m is length of pattern
  int j;
  for(int i=0; i \le (n-m); i++) {
   j = 0;
    while ((j < m) && (text.charAt(i+j) == pattern.charAt(j))
       j++;
    if (j == m)
        return i; // match at i
  return -1; // no match
} // end of brute()
```

```
public static void main(String args[])
{ if (args.length != 2) {
    System.out.println("Usage: java BruteSearch
                              <text> <pattern>");
    System.exit(0);
  System.out.println("Text: " + args[0]);
  System.out.println("Pattern: " + args[1]);
  int posn = brute(args[0], args[1]);
  if (posn == -1)
    System.out.println("Pattern not found");
  else
    System.out.println("Pattern starts at posn "
                                  + posn);
```

# Analysis

#### Worst Case.

- ❖ Jumlah perbandingan: m(n m + 1) = O(mn)
- Contoh:
  - T: "aaaaaaaaaaaaaaaaaaaaaaaaaah"
  - − P: "aaah"

#### Best case

- \* Kompleksitas kasus terbaik adalah O(n).
- ❖ Terjadi bila karakter pertama pattern P tidak pernah sama dengan karakter teks T yang dicocokkan
- ❖ Jumlah perbandingan maksimal *n* kali:
- \* Contoh:

T: String ini berakhir dengan zzz

P: zzz

#### **Average Case**

❖ But most searches of ordinary text take O(m+n), which is very quick.

- \* Example of a more average case:
  - T: "a string searching example is standard"
  - − P: "store"

- The brute force algorithm is fast when the alphabet of the text is large
  - e.g. A..Z, a..z, 1..9, etc.

- \* It is slower when the alphabet is small
  - e.g. 0, 1 (as in binary files, image files, etc.)

# Knuth-Morris-Pratt (KMP) Algorithm

- Pada algoritma brute force, jika terjadi mismatch, maka dilakukan pergeseran pattern sebanyak 1 karakter.
- Sedangkan pada algoritma Knuth-Morris-Pratt (KMP), setiap terjadi mismatch, pergeseran dilakukan berdasarkan informasi pattern (longest-prefix-suffix atau border function) yang telah diproses sebelum pencarian dimulai.
- Dengan informasi ini, jumlah pergeseran karakter dilakukan sesuai dengan informasi pattern yang dimiliki.

#### Ilustrasi

```
    Text: dead deadpool.
    Pattern: deadpool
    dead deadpool
    deadpool
    deadpool
    deadpool
    deadpool
    deadpool
    deadpool
    deadpool
```

- Pattern 'deadpool' ditemukan pada karakter ke-6 text dengan 15 perbandingan karakter.
- Jika menggunakan brute force, diperlukan sebanyak 17 perbandingan karakter.
- Kompleksitas waktu untuk memproses border function adalah O(m), sedangkan pencarian pada text membutuhkan waktu O(n).
- Maka, kompleksitas waktu algoritma KMP adalah O(m+n).


\* The Knuth-Morris-Pratt (KMP) algorithm looks for the pattern in the text in a *left-to-right* order (like the brute force algorithm).

But it shifts the pattern more intelligently than the brute force algorithm.


**Donald Ervin Knuth** (born January 10, 1938) is a <u>computer scientist</u> and <u>Professor Emeritus</u> at <u>Stanford University</u>. He is the author of the seminal multi-volume work <u>The Art of Computer Programming</u>. [3] Knuth has been called the "father" of the <u>analysis of algorithms</u>. He contributed to the development of the rigorous analysis of the computational complexity of algorithms and systematized formal mathematical techniques for it. In the process he also popularized the <u>asymptotic notation</u>.

If a mismatch occurs between the text and pattern P at P[j], i.e T[i] ≠ P[j], what is the most we can shift the pattern to avoid wasteful comparisons?

\* Answer: the largest prefix of P[0 .. j-1] that is a suffix of P[1 .. j-1]



```
Find largest prefix (start) of:
           "abaab" (P[0..4])
  which is suffix (end) of:
           "abaab" (P[1..4])
♦ Answer: "ab" \rightarrow panjang = 2
\Leftrightarrow Set j = 2 // the new j value to begin comparison
Jumlah pergeseran:
s = \text{panjang(abbab)} - \text{panjang(ab)}
   = 5 - 2 = 3
```



# Fungsi Pinggiran KMP (KMP Border Function)

- \* KMP preprocesses the pattern to find matches of prefixes of the pattern with the pattern itself.
- $\star$  k = position before the mismatch (k = j-1).
- ❖ The border function b(k) is defined as the size of the largest prefix of P[0..k] that is also a suffix of P[1..k].
- \* The other name: *failure function* (disingkat: *fail*)

## **Border** Function Example

(k = j-1)

❖ P: abaaba

j: 012345

j	0	1	2	3	4	5
P[j]	а	b	а	a	b	а
k	ı	0	1	2	3	4
b(k)	-	0	0	1	1	2

b(k) is the size of the largest border.


In code, b() is represented by an array, like the table.

# Why is b(4) == 2?

P: "abaaba"

- **⋄** b(4) means
  - find the size of the largest prefix of P[0..4] that is also a suffix of P[1..4]
  - find the size largest prefix of "abaab" that is also a suffix of "baab"
  - find the size of "ab"

= 2



## Using the Border Function

- \* Knuth-Morris-Pratt's algorithm modifies the brute-force algorithm.
  - if a mismatch occurs at P[j]
    (i.e. P[j] != T[i]), then
    k = j-1;
    j = b(k); // obtain the new j


#### Return index where KMP in Java pattern starts, or -1 public static int kmpMatch (String text, String pattern) int n = text.length(); int m = pattern.length(); int fail[] = computeFail(pattern); int i=0;int j=0;

```
while (i < n) {
   if (pattern.charAt(j) == text.charAt(i)) {
     if (j == m - 1)
       return i - m + 1; // match
     i++;
     j++;
   else if (j > 0)
     j = fail[j-1];
   else
     i++;
 return -1; // no match
} // end of kmpMatch()
```

```
public static int[] computeFail(
                          String pattern)
  int fail[] = new int[pattern.length()];
  fail[0] = 0;
  int m = pattern.length();
  int j = 0;
  int i = 1;
```

```
while (i < m) {
   if (pattern.charAt(j) ==
       pattern.charAt(i)) { //j+1 chars match
     fail[i] = j + 1;
     i++;
     j++;
   else if (j > 0) // j follows matching prefix
     j = fail[j-1];
   else { // no match
     fail[i] = 0;
     i++;
                               Similar code
                              to kmpMatch()
 return fail;
} // end of computeFail()
```

#### Usage public static void main(String args[]) { if (args.length != 2) { System.out.println("Usage: java KmpSearch <text> <pattern>"); System.exit(0); System.out.println("Text: " + args[0]); System.out.println("Pattern: " + args[1]); int posn = kmpMatch(args[0], args[1]); if (posn == -1)System.out.println("Pattern not found"); else System.out.println("Pattern starts at posn " + posn);



## Why is b(4) == 1?

P: "abacab"

- **⋄** b(4) means
  - find the size of the largest prefix of P[0..4] that is also a suffix of P[1..4]
  - = find the size largest prefix of "abaca" that is also a suffix of "baca"
  - = find the size of "a"
  - = 1

#### Kompleksitas Waktu KMP


- \* Menghitung fungsi pinggiran : O(m),
- \* Pencarian string : O(n)
- \* Kompleksitas waktu algoritma KMP adalah O(m+n).
  - sangat cepat dibandingkan brute force

# KMP Advantages

- \* The algorithm never needs to move backwards in the input text, T
  - this makes the algorithm good for processing very large files that are read in from external devices or through a network stream

## KMP Disadvantages

- \* KMP doesn't work so well as the size of the alphabet increases
  - more chance of a mismatch (more possible mismatches)
  - mismatches tend to occur early in the pattern,
     but KMP is faster when the mismatches occur later



## Boyer-Moore Algorithm

- Algoritma Boyer-Moore didasarkan pada dua teknik, yakni:
- 1. The looking glass technique, yakni membandingkan karakter pada pattern dan text dimulai dari belakang-kedepan (dimulai dari karakter terakhir pattern)
- 2. The character-jump technique, yakni jika terjadi mismatch pada karakter x di text T[i] dengan karakter y di pattern P[j], maka ada 3 kasus yang dicoba secara berurutan, yakni:
  - a. Jika P berisi karakter x di kiri dari lokasi mismatch, maka sejajarkan x dengan kemunculan terakhir x pada pattern.
  - b. Jika P berisi karakter x hanya di kanan dari lokasi mismatch, maka geser pattern sebanyak 1 karakter ke kanan.
  - c. Jika P tidak berisi karakter x, maka sejajarkan P[1] dengan T[i+1].

#### Ilustrasi

- Text: dead deadly deadpool.
- Pattern: deadpool
- dead deadly deadpool.


dead deadly deadpool.


1 deadpool
2 deadpool
3 deadpool
4 deadpool


- Pattern 'deadpool' ditemukan pada karakter ke-13 text dengan 11 perbandingan karakter.
- Kompleksitas waktu terburuk algoritma Boyer-Moore adalah O(mn+A), dimana A adalah waktu yang dibutuhkan untuk melakukan pre-processing alfabet pada pattern


\* The Boyer-Moore pattern matching algorithm is based on two techniques.


- \* 1. The *looking-glass* technique
  - find P in T by moving backwards through P, starting at its end












#### Last Occurrence Function


- \*Boyer-Moore's algorithm preprocesses the pattern P and the alphabet A to build a last occurrence function L()
  - L() maps all the letters in A to integers
- ❖ L(x) is defined as:
  // x is a letter in A
  - the largest index i such that P[i] == x, or
  - -1 if no such index exists



# Note

\* In Boyer-Moore code, L() is calculated when the pattern P is read in.

- Usually L() is stored as an array
  - something like the table in the previous slide



## Boyer-Moore in Java pattern starts, or -1

Return index where

```
public static int bmMatch (String text,
                               String pattern)
  int last[] = buildLast(pattern);
  int n = text.length();
  int m = pattern.length();
  int i = m-1;
  if (i > n-1)
    return -1; // no match if pattern is
               // longer than text
```

```
= m-1;
  if (pattern.charAt(j) == text.charAt(i))
    if (j == 0)
      return i; // match
    else { // looking-glass technique
      i--;
      j--;
  else { // character jump technique
     int lo = last[text.charAt(i)]; //last occ
     i = i + m - Math.min(j, 1+lo);
     j = m - 1;
} while (i <= n-1);</pre>
return -1; // no match
// end of bmMatch()
```

```
public static int[] buildLast(String pattern)
/* Return array storing index of last
  occurrence of each ASCII char in pattern. */
  int last[] = new int[128]; // ASCII char set
  for (int i=0; i < 128; i++)
    last[i] = -1; // initialize array
  for (int i = 0; i < pattern.length(); i++)</pre>
    last[pattern.charAt(i)] = i;
  return last;
} // end of buildLast()
```

#### Usage public static void main(String args[]) { if (args.length != 2) { System.out.println("Usage: java BmSearch <text> <pattern>"); System.exit(0); System.out.println("Text: " + args[0]); System.out.println("Pattern: " + args[1]); int posn = bmMatch(args[0], args[1]); if (posn == -1)System.out.println("Pattern not found"); else System.out.println("Pattern starts at posn " + posn);

#### Analysis

- ❖ Boyer-Moore worst case running time is O(nm + A)
- \*But, Boyer-Moore is fast when the alphabet (A) is large, slow when the alphabet is small.
  - e.g. good for English text, poor for binary
- Boyer-Moore is significantly faster than brute force for searching English text.

